




Direkte Löser Linearer Gleichungssysteme

Lineare Gleichungssysteme

Maximale Ungenauigkeit

Determinanten-Basierte Methoden

Gestaffelte Systeme

- Diagonalmatrizen

- Dreiecksmatrizen

- Gaußsche Eliminationsmethode

- Pivotisierung

- Cholesky-Zerlegung

- Bandmatrizen

Lineare Gleichungssysteme

Drei Bauern handeln auf einem Markt Rinder, Schafe und Schweine. Der erste Bauer verkauft 2 Rinder und 5 Schafe und kauft 13 Schweine, wobei 1000 Geldstücke übrig bleiben. Der zweite verkauft 3 Rinder und 3 Schweine, wofür er genau 9 Schafe bekommt. Der dritte Bauer verkauft 6 Schafe und 8 Schweine und kauft 5 Rinder, wobei er noch 600 Geldstücke drauflegen muss. Wie hoch ist der Preis eines Rinds, eines Schafs und eines Schweins?

Linearer Gleichungssysteme

Satz

Sei $A \in \mathbb{R}^{n \times n}$ mit $\det(A) \neq 0$ und $b \in \mathbb{R}^n$.

Dann existiert genau ein $x \in \mathbb{R}^n$, sodass $Ax = b$ ist.

⇒ Wichtige **Voraussetzung**: Determinante der Matrix A ist nicht null!

⇒ Eindeutige Lösung des linearen Gleichungssystems

Fehler und Residuum

Definition

Sei $x := A^{-1}b$ die exakte (aber im Allgemeinen unbekannte) Lösung des linearen Gleichungssystems $Ax = b$ und $\tilde{x}$ eine Näherungslösung.

Dann heißt $e := x - \tilde{x}$ **Fehler** und $r := b - A\tilde{x}$ das **Residuum**.

Es gilt folgender Zusammenhang:

$$Ae = Ax - A\tilde{x} = b - A\tilde{x} = r.$$

Daraus folgt mit einer Vektornorm $\|\cdot\|$ und einer damit verträglichen Matrixnorm:

$$\|e\| = \|A^{-1}r\| \leq \|A^{-1}\| \|r\| \quad \text{und} \quad \|b\| = \|Ax\| \leq \|A\| \|x\|.$$

Kondition und relativer Fehler

Definition

Die **Konditionszahl** einer regulären Matrix A bezüglich der verwendeten Matrixnorm lautet

$$\kappa(A) \equiv \kappa_{\|\cdot\|}(A) := \|A\| \|A^{-1}\|.$$

Damit erhalten wir nun eine einfache Abschätzung für den relativen Fehler

$$\frac{\|x - \tilde{x}\|}{\|x\|} = \frac{\|e\|}{\|x\|} \leq \frac{\|A^{-1}\| \|r\|}{\|b\| \cdot \frac{1}{\|A\|}} = \|A^{-1}\| \|A\| \cdot \frac{\|r\|}{\|b\|} = \kappa(A) \frac{\|r\|}{\|b\|}. \quad (1)$$

Beispiel

Sei $\tilde{x} = (1 - \varepsilon)x$ mit $\varepsilon > 0$. Dann lautet der relative Fehler

$$\frac{\|x - \tilde{x}\|}{\|x\|} = \frac{\|e\|}{\|x\|} = \frac{\|\varepsilon x\|}{\|x\|} = \varepsilon.$$

Das Residuum lautet $r = b - A\tilde{x} = Ax - A\tilde{x} = A(x - (1 - \varepsilon)x) = \varepsilon Ax = \varepsilon b$, also

$$\frac{\|r\|}{\|b\|} = \frac{\|\varepsilon b\|}{\|b\|} = \varepsilon = \frac{\|x - \tilde{x}\|}{\|x\|}.$$

■

⇒ Abschätzung (1) offenbar **zu pessimistisch**. Insbesondere, wenn $\kappa(A)$ sehr groß ist.

⇒ Abschätzung (1) ist eine “worst case Abschätzung”.

Beispiel

$$A = \begin{pmatrix} 1 & \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} \\ \frac{1}{2} & \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} \\ \frac{1}{3} & \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} \\ \frac{1}{4} & \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} \\ \frac{1}{5} & \frac{1}{6} & \frac{1}{7} & \frac{1}{8} & \frac{1}{9} \end{pmatrix}, \quad b := (b_j)_{j=1,\dots,5} \quad \text{mit} \quad b_j := \sum_{k=1}^5 \frac{1}{k+j-1}.$$

Exakte Lösung lautet $x = (1, \dots, 1)^T$.

Für das Verhältnis $\frac{\|e\|}{\|x\|} \frac{\|b\|}{\kappa_{\|\cdot\|}(A) \|r\|}$ erhält man:
(in Abhängigkeit der verwendeten Norm)

$\ \cdot\ _1$	$\ \cdot\ _2$	$\ \cdot\ _\infty$
≈ 0.41	≈ 0.89	≈ 0.74



$\Rightarrow$ Abschätzung (1) ist **nahezu scharf**.

Störungen der Daten

Satz

Sei $A \in \mathbb{R}^{n \times n}$ regulär und $x := A^{-1}b \in \mathbb{R}^n$. Es seien δb und δA Störungen von b bzw. A , so dass $A + \delta A$ regulär sei und

$$\kappa(A) \|\delta A\| / \|A\| < 1$$

gelte. Dann gilt für $\tilde{x} := (A + \delta A)^{-1}(b + \delta b)$ die Fehlerabschätzung

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\delta A\|}{\|A\|}} \left(\frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right). \quad (2)$$

Störungen der Daten

Bemerkung

Für sehr kleine Störungen, d.h. für $\kappa(A) \frac{\|\delta A\|}{\|A\|} \ll 1$ wird (2) zu

$$\frac{\|x - \tilde{x}\|}{\|x\|} \lesssim \kappa(A) \left(\frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right),$$

die Konditionszahl ist also die entscheidende Größe, welche die Empfindlichkeit der Lösung bzgl. der Daten-Störungen δA und δb ausdrückt.

Störungen der Daten

Angenommen, der relative Fehler der Ausgangsgrößen ist

$$\frac{\|\delta A\|}{\|A\|} \approx 5 \cdot 10^{-d} \quad \frac{\|\delta b\|}{\|b\|} \approx 5 \cdot 10^{-d}.$$

Ferner sei die Konditionszahl in der Größenordnung $\kappa(A) \approx 10^\alpha$ mit $5 \cdot 10^{\alpha-d} \ll 1$.

Dann ergibt die Abschätzung (2):

$$\|\delta x\| \leq 10^{\alpha-d+1} \|x\|.$$

Bemerkung (Faustregel)

Wird ein LGS $Ax = b$ mit d -stelliger dezimaler Gleitkomma-Rechnung gelöst, und beträgt die Konditionszahl $\kappa(A) \approx 10^\alpha$, so sind (bezogen auf die betragsgrößte Komponente) nur $(d - \alpha - 1)$ Dezimalstellen sicher.

Cramersche Regel

Falls $\det A \neq 0$, so lässt sich $x = A^{-1}b$ mit der **Cramerschen Regel** berechnen, d.h.

$$x_i = \frac{1}{\det A} \begin{vmatrix} a_{11} & \dots & b_1 & \dots & a_{1n} \\ a_{21} & \dots & b_2 & \dots & a_{2n} \\ \vdots & & \vdots & & \vdots \\ a_{nn} & \dots & b_n & \dots & a_{nn} \end{vmatrix} = \frac{D_i}{D} \quad (i = 1, \dots, n).$$

Dabei geht die im Zähler stehende Determinante D_i dadurch aus $D = \det A$ hervor, dass man die i -te Spalte der Matrix A durch den Vektor b der rechten Seite ersetzt.

Bemerkung (Verbindung zu Existenz- und Eindeutigkeits-Aussage)

Die Cramersche Regel führt genau dann zu einem Ergebnis, wenn das Problem lösbar ist (und sonst abbricht).

Rechenaufwand / FLOP

Im folgenden werden wir zwei Methoden zur Berechnung der Determinante vorstellen:

- ▶ mittels **Leibnizscher Darstellung**,
- ▶ mittels **Laplaceschen Entwicklungssatzes**.

Insbesondere wollen wir den benötigten Rechenaufwand betrachten.

Bemerkung (Rechenaufwand)

Im Folgenden werden die Verknüpfungen Multiplikation, Addition, Division und Subtraktion in ihrem Rechenaufwand nicht unterschieden und unter dem Begriff **Gleitkommaoperation** zusammengefasst (1 Gleitkommaoperation $\simeq$ 1 FLOP).

Multiplikationen mit ± 1 bleiben im Allgemeinen unberücksichtigt.

Anderweitige Operationen wie z.B. Wurzelziehen werden gesondert betrachtet.

Die Determinante von $A \in \mathbb{R}^{n \times n}$ lautet in der **Leibnizschen Darstellung**

$$\det A = \sum_{\pi} (-1)^{j(\pi)} a_{1i_1} a_{2i_2} \cdots a_{ni_n},$$

wobei die Summe über alle möglichen $n!$ Permutationen π der Zahlen $1, 2, \dots, n$ zu berechnen ist. Der Wert des Ausdrucks $(-1)^{j(\pi)}$ ergibt sich aus der Anzahl $j(\pi)$ der Inversionen der Permutation $\pi = \begin{pmatrix} 1 & 2 & \dots & n \\ i_1 & i_2 & \dots & i_n \end{pmatrix}$.

Satz (Aufwand Leibnizsche Darstellung)

Der Aufwand zur Berechnung von $\det A$ für $A \in \mathbb{R}^{n \times n}$ mit der Leibnizschen Darstellung beträgt

$$\text{FLOP}(\det A) = n n! - 1.$$

Die Determinante von $A \in \mathbb{R}^{n \times n}$ lässt sich rekursiv mit Hilfe des **Laplaceschen Entwicklungssatzes** berechnen:

$$\det A = \sum_{j=1}^n (-1)^{1+j} a_{1j} \det(A_{1j}),$$

wobei A_{1j} diejenige Matrix ist, die aus A durch Streichen der ersten Zeile und der j -ten Spalte entsteht.

Satz (Aufwand Laplacescher Entwicklungssatz)

Sei $A \in \mathbb{R}^{n \times n}$ ($n \geq 2$). Der Aufwand zur Berechnung von $\det A$ mit dem Laplaceschen Entwicklungssatz beträgt

$$\text{FLOP}(\det A) = \sum_{k=0}^n \frac{n!}{k!} - 2 < e n! - 2.$$

Theoretische Berechnungszeiten

- ▶ 2008: JUGENE, schnellster europäischen Rechner;
Leistung: $180 \cdot 10^{12}$ FLOPs.
- ▶ 2023: Frontier, Nr. 1 der Top 500 Liste;
Leistung: $1.1 \cdot 10^{18}$ FLOPs.

n	2008	2023
20	10.21 [hrs]	0.10 [min]
21	214.32 [hrs]	2.10 [min]
22	0.54 [yrs]	0.77 [hrs]
23	12.37 [yrs]	17.75 [hrs]
24	296.92 [yrs]	0.60 [mon]
25	7422.88 [yrs]	1.21 [yrs]
26	192994.95 [yrs]	31.58 [yrs]

Diagonalmatrizen

Algorithmus (Lösen von $Ax = b$ mit Diagonalmatrix A)

Input $A \in \mathbb{R}^{n \times n}$ Diagonalmatrix mit $a_{ii} \neq 0$, $b \in \mathbb{R}^n$

for $i = 1, \dots, n$

$$x_i = b_i / a_{ii}$$

end

Output $x = (x_1, \dots, x_n)^T$

Dreiecksmatrizen

Definition

1. Sei $A = (a_{ij})_{i,j=1,\dots,n} \in \mathbb{R}^{n \times n}$.

Dann heißt A :

- ▶ *obere Dreiecksmatrix*, falls $a_{ij} = 0$ für $i > j$, und
- ▶ *untere Dreiecksmatrix*, falls $a_{ij} = 0$ für $i < j$.

2. A heißt *Dreiecksmatrix*, wenn A entweder eine untere oder eine obere Dreiecksmatrix ist.
3. A heißt *unipotente Dreiecksmatrix*, falls zusätzlich $a_{ii} = 1$, $i = 1, \dots, n$.
4. Ein Gleichungssystem $Ax = b$ mit einer Dreiecksmatrix A heißt *gestaffelt*.

Rückwärtssubstitution

Für R **obere Dreiecksmatrix** hat $Rx = z$ hat die Form

$$\begin{array}{ccccccc} r_{11}x_1 & + & r_{12}x_2 & + & \cdots & + & r_{1n}x_n & = & z_1 \\ & & r_{22}x_2 & + & \cdots & + & r_{2n}x_n & = & z_2 \\ & & & & \ddots & & \vdots & & \vdots \\ & & & & & & r_{nn}x_n & = & z_n \end{array}$$

Falls alle $r_{ii} \neq 0$, sukzessives auflösen (beginnend mit der **letzten** Zeile):

$$\begin{array}{llll} x_n & := & z_n / r_{nn}, & \text{falls } r_{nn} \neq 0, \\ x_{n-1} & := & (z_{n-1} - r_{n-1,n}x_n) / r_{n-1,n-1}, & \text{falls } r_{n-1,n-1} \neq 0, \\ \vdots & \vdots & \vdots & \vdots \\ x_k & := & (z_k - \sum_{i=k+1}^n r_{ki}x_i) / r_{kk}, & \text{falls } r_{kk} \neq 0, \\ \vdots & \vdots & \vdots & \vdots \\ x_1 & := & (z_1 - r_{12}x_2 - \dots - r_{1n}x_n) / r_{11}, & \text{falls } r_{11} \neq 0. \end{array}$$

Vorwärtssubstitution

- ▶ Analog zu obigem lässt sich auch ein gestaffeltes lineares Gleichungssystem der Form

$$Lx = z$$

mit einer **unteren Dreiecksmatrix** $L \in \mathbb{R}^{n \times n}$ lösen.

- ▶ In diesem Fall beginnt man in der ersten Zeile mit der Berechnung von x_1 und arbeitet sich dann bis zur letzten Zeile zur Bestimmung von x_n vor.

↪ Dies bezeichnet man als *Vorwärtssubstitution* oder *Vorwärtseinsetzen*.

Satz (Rechenaufwand für Dreiecksmatrizen)

Sei $A \in \mathbb{R}^{n \times n}$ eine reguläre Dreiecksmatrix und $x, b \in \mathbb{R}^n$. Dann gilt für die Matrix-Vektor-Multiplikation Ax und die Lösung $A^{-1}b$ des gestaffelten Systems

$$\text{FLOP}(Ax) = n^2 \quad \text{und} \quad \text{FLOP}(A^{-1}b) = n^2.$$

Bei der Berechnung von $A^{-1}b$ ist im Gegensatz zu Ax die Reihenfolge, in der die Zeilen abgearbeitet werden, festgelegt.

Bemerkung

Die Bezeichnung $\text{FLOP}(A^{-1}b)$ **bedeutet nicht**, dass man erst die Inverse A^{-1} bestimmt und diese dann mit einem Vektor multipliziert, sondern ist ein Synonym für die Lösung des linearen Gleichungssystems.

Implementierung

```
1  function x = Rinvb(R,z)
2  % compute solution of  $R*x=z$ 
3  % with upper triangular R
4
5  n = size(R,1);
6  x = zeros(n,1);
7  for j = n:-1:1
8      for k=j+1:n
9          z(j) = z(j)-R(j,k)*x(k);
10     end
11     x(j) = z(j)/R(j,j);
12 end
```

```
1  function x = Rinvb2(R,z)
2  % compute solution of  $R*x=z$ 
3  % with upper triangular R
4
5  n = size(R,1);
6  x = zeros(n,1);
7  for j = n:-1:1
8      x(j) = z(j)/R(j,j);
9      for k=1:j-1
10         z(k) = z(k)-R(k,j)*x(j);
11     end
12 end
```

LR-Zerlegung

Definition (LR-Zerlegung)

Seien $A \in \mathbb{R}^{n \times n}$ sowie $R \in \mathbb{R}^{n \times n}$ rechte obere und $L \in \mathbb{R}^{n \times n}$ eine unipotente linke untere Dreiecksmatrix. Falls $A = L \cdot R$, so nennt man dies eine **LR-Zerlegung** von A .

Nehmen wir an für $A \in \mathbb{R}^{n \times n}$ existiert diese Zerlegung.

i) bestimme $A = L \cdot R$

ii) löse $Lz = b$
(Vorwärtseinsetzen)

iii) löse $Rx = z$
(Rückwärtseinsetzen)

Für $b \in \mathbb{R}^n$ berechne nacheinander:

↪ **Gaußsche Eliminationsmethode**

- Seien $A \in \mathbb{R}^{n \times n}$ regulär sowie $b \in \mathbb{R}^n$ gegeben und wir betrachten ein lineares Gleichungssystem $Ax = b$, also komponentenweise

$$\begin{array}{ccccccccc} a_{11} x_1 & + & a_{12} x_2 & + & \cdots & + & a_{1n} x_n & = & b_1 \\ a_{21} x_1 & + & a_{22} x_2 & + & \cdots & + & a_{2n} x_n & = & b_2 \\ \vdots & & \vdots & & & & \vdots & & \vdots \\ a_{n1} x_1 & + & a_{n2} x_2 & + & \cdots & + & a_{nn} x_n & = & b_n \end{array} \quad (3)$$

- Durchführung von Äquivalenzoperationen verändert die Lösungsmenge nicht!
- Äquivalenzoperationen:
1. Vertauschung von Zeilen,
 2. Multiplikation einer Zeile mit einem Skalar $\neq 0$,
 3. Addition eines Vielfachen einer Zeile zu einer anderen,

Ziel: Überführung in ein gestaffeltes System.

- Im ersten Schritt soll (3) übergeführt werden in:

$$\begin{array}{ccccccc} a_{11}x_1 & + & a_{12}x_2 & + & \cdots & + & a_{1n}x_n & = & b_1 \\ & & a'_{22}x_2 & + & \cdots & + & a'_{2n}x_n & = & b'_2 \\ & & \vdots & & & & \vdots & & \vdots \\ & & a'_{n2}x_2 & + & \cdots & + & a'_{nn}x_n & = & b'_n. \end{array}$$

- Dazu

- definiere *Multiplikatoren* $l_{i1} := a_{i1}/a_{11}$, $i = 2, 3, \dots, n$,
- berechne damit a'_{ik} , b'_i via

$$a'_{ik} = a_{ik} - l_{i1} a_{1k}, \quad b'_i = b_i - l_{i1} b_1.$$

- Wende dasselbe Verfahren auf

- die Restmatrix $(a'_{i,j})_{i,j=2,\dots,n} \in \mathbb{R}^{(n-1) \times (n-1)}$ und
- den Restvektor $(b'_i)_{i=2,\dots,n} \in \mathbb{R}^{n-1}$ an.

- Rekursives durchführen liefert formal Folge von (Rest-)Matrizen

$$A = A^{(1)} \rightarrow A^{(2)} \rightarrow \dots \rightarrow A^{(n)} =: R$$

- der speziellen Gestalt

$$A^{(k)} = \begin{pmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \dots & & a_{1n}^{(1)} \\ & a_{22}^{(2)} & \dots & & a_{2n}^{(2)} \\ & & \ddots & & \\ & & & a_{kk}^{(k)} & \dots & a_{kn}^{(k)} \\ & & & \vdots & & \vdots \\ & & & a_{nk}^{(k)} & \dots & a_{nn}^{(k)} \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

- **Eliminationsschritt** für $k = 1, \dots, n$:

$$l_{ik} := a_{ik}^{(k)} / a_{kk}^{(k)} \quad \text{für } i = k + 1, \dots, n,$$

$$a_{ij}^{(k+1)} := a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)} \quad \text{für } i, j = k + 1, \dots, n,$$

falls die sogenannten **Pivotelemente** $a_{kk}^{(k)}$ nicht verschwinden.

$$l_{ik} := a_{ik}^{(k)} / a_{kk}^{(k)}$$
$$a_{ij}^{(k+1)} := a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)}$$

```
1 function [L,R] = my_lr(A)
2     n = size(A,1);
3     L = zeros(n);
4     for k=1:n
5         for i=k+1:n
6             L(i,k) = A(i,k)/A(k,k);
7             for j=k+1:n
8                 A(i,j) = ...
9                     A(i,j) - L(i,k)*A(k,j);
10            end
11        end
12    end
13    L = L+eye(n);
14    R = triu(A);
15 end
```

Rechenaufwand

Satz (Rechenaufwand)

Sei $A \in \mathbb{R}^{n \times n}$ regulär mit existierender LR-Zerlegung $A = LR$ und $b \in \mathbb{R}^n$. Dann gilt

$$\text{FLOP}(\text{LR-Zerlegung}) = \frac{1}{6}(4n^3 - 3n^2 - n),$$

$$\text{FLOP}(A^{-1}b) = \frac{1}{6}(4n^3 + 9n^2 - n),$$

d.h. die Lösung von $Ax = b$ kann in $\mathcal{O}(n^3)$ FLOPs berechnet werden.

Speicheraufwand

- Betrachte nochmals die Folge:

$$A = A^{(1)} \rightarrow A^{(2)} \rightarrow \dots \rightarrow A^{(n)} =: R.$$

- Nach jedem Eliminationsschritt verschwindet die Spalte unter dem Pivotelement.
 ► Die Diagonalelemente von L sind identisch 1 (müssen nicht gespeichert werden).

~> Bei der Durchführung der *LR-Zerlegung* einer Matrix $A \in \mathbb{R}^{n \times n}$ kann man L und R in **derselben** Matrix im Speicher ablegen:

$$A \rightarrow \begin{pmatrix} \overline{a_{11}^{(1)}} & \dots & \dots & a_{1n}^{(1)} \\ l_{21} & \overline{a_{22}^{(2)}} & \dots & a_{2n}^{(2)} \\ \vdots & \vdots & & \\ l_{n1} & \overline{a_{n2}^{(2)}} & & a_{nn}^{(2)} \end{pmatrix} \rightarrow \dots \rightarrow \begin{pmatrix} \overline{a_{11}^{(1)}} & \dots & & a_{1n}^{(1)} \\ l_{21} & \overline{a_{22}^{(2)}} & & a_{2n}^{(2)} \\ \vdots & \ddots & & \\ \vdots & & \ddots & \\ l_{n1} & \dots & \dots & \overline{l_{n,n-1}} & a_{nn}^{(n)} \end{pmatrix}$$

~> Falls A nicht mehr benötigt wird, sogar **inplace**.

Eindeutigkeit

Satz (Eindeutigkeit der LR-Zerlegung)

Existiert eine *LR-Zerlegung*, so sind L und R eindeutig bestimmt.

Achtung Daraus folgt **nicht**, dass für jede reguläre Matrix die vorgestellte *LR-Zerlegung* existiert!

Beispiel

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ a & 1 \end{pmatrix} \begin{pmatrix} b & c \\ 0 & d \end{pmatrix} = \begin{pmatrix} b & c \\ ab & ac + d \end{pmatrix}$$

Beispiel

Für $\varepsilon > 0$ betrachten wir die Lösung von Lösung **ohne** Permutation:

$$\varepsilon x_1 + x_2 = 1,$$

$$x_1 + x_2 = 2.$$

$$\varepsilon x_1 + x_2 = 1,$$

$$\left(1 - \frac{1}{\varepsilon}\right) x_2 = 2 - \frac{1}{\varepsilon}.$$

Bei **exakter Arithmetik**:

$\rightsquigarrow x_2 \leftarrow 1$ und $x_1 \leftarrow 0$ (falls ε klein genug).

$$\frac{1}{\varepsilon-1} \begin{pmatrix} 1 & -1 \\ -1 & \varepsilon \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \frac{1}{1-\varepsilon} \begin{pmatrix} 1 \\ 1-2\varepsilon \end{pmatrix}$$

Lösung **mit** Permutation:

$$x_1 + x_2 = 2,$$

$$(1 - \varepsilon) x_2 = 1 - 2\varepsilon.$$

$$\rightsquigarrow x_1^* = \frac{1}{1-\varepsilon} \text{ und } x_2^* = \frac{1-2\varepsilon}{1-\varepsilon}.$$

Gleitkommadarstellung für $2\varepsilon < \epsilon$:

$\rightsquigarrow x_2 \leftarrow 1$ und $x_1 \leftarrow 1$.

$\rightsquigarrow x_1 \leftarrow 1$ und $x_2 \leftarrow 1$.

Take-away der letzten zwei Beispiele:

- ▶ Nicht jede reguläre Matrix besitzt eine LR-Zerlegung.
- ▶ Vertauschung der Zeilen (Permutationen des Indizes) liefert u.U.
 - ▶ eine LR-Zerlegung
 - ▶ höhere Genauigkeit.

Erinnerung

Äquivalenzoperationen, die die Lösungsmenge nicht verändern:

1. Multiplikation einer Zeile mit einem Skalar $\neq 0$,
2. Addition eines Vielfachen einer Zeile zu einer anderen,
3. Vertauschung von Zeilen.

Algorithmus (Gauß-Elimination mit Spaltenpivotisierung)

- a) Wähle im Eliminationsschritt $A^{(k)} \rightarrow A^{(k+1)}$ einen Index $p \in \{k, \dots, n\}$, so dass

$$|a_{pk}^{(k)}| \geq |a_{jk}^{(k)}| \quad \text{für } j = k, \dots, n.$$

Die Zeile p soll die **Pivotzeile**, $a_{pk}^{(k)}$ das **Pivotelement**, werden.

- b) Vertausche die Zeilen p und k

$$A^{(k)} \rightarrow \tilde{A}^{(k)} \quad \text{mit} \quad \tilde{a}_{ij}^{(k)} = \begin{cases} a_{kj}^{(k)}, & \text{falls } i = p, \\ a_{pj}^{(k)}, & \text{falls } i = k, \\ a_{ij}^{(k)}, & \text{sonst.} \end{cases}$$

$$\text{Nun gilt } |l_{ik}| = \left| \frac{\tilde{a}_{ik}^{(k)}}{\tilde{a}_{kk}^{(k)}} \right| = \left| \frac{\tilde{a}_{ik}^{(k)}}{a_{pk}^{(k)}} \right| \leq 1.$$

- c) Führe den nächsten Eliminationsschritt angewandt auf $\tilde{A}^{(k)}$ aus, $\tilde{A}^{(k)} \rightarrow A^{(k+1)}$.

Pivotstrategien und deren Aufwand

- ▶ Anstelle der **Spaltenpivotisierung** mit *Zeilentausch* kann man auch eine **Zeilenpivotisierung** mit *Spaltentausch* durchführen.
- ▶ Beide Strategien benötigen $\mathcal{O}(n^2)$ zusätzliche Operationen.
- ▶ In der Praxis keine Umspeicherung der Zeilen bzw. Spalten.
 $\rightsquigarrow$ Verwendung von Indexvektoren.
- ▶ Kombination von Spalten- und Zeilenpivotisierung:
 $\rightsquigarrow$ **vollständigen Pivotsuche** (Aber: Aufwand $\mathcal{O}(n^3)$!)

Existenz der LR-Zerlegung (cont'd)

Satz

Sei $A \in \mathbb{R}^{n \times n}$ regulär.

- ▶ Vor dem k -ten Eliminationsschritt des Gauß-Algorithmus existiert stets eine Zeilen-/Spaltenpermutation derart, dass das k -te Diagonalelement von Null verschieden ist.
- ▶ Bei Zeilenpermutation (Spaltenpivotisierung) sind alle Einträge von L vom Betrag kleiner oder gleich eins.

Definition

Eine Matrix $P \in \{0, 1\}^{n \times n}$ heißt **Permutationsmatrix**, welche jede Zeile und jede Spalte genau eine Eins und sonst nur Nullen enthält.

Lemma

Sei P eine Permutationsmatrix, dann gilt $\det P = \pm 1$ und $P^{-1} = P^T$.

Satz (Existenz einer Zerlegung $PA = LR$)

Zu jeder regulären Matrix A existiert eine Permutationsmatrix P , so dass

$$P \cdot A = L \cdot R.$$

Definition

Eine Matrix $A = (a_{ij})_{i,j=1,\dots,n} \in \mathbb{R}^{n \times n}$ heißt

- **schwach diagonaldominant**, falls

$$|a_{ii}| \geq \sum_{\substack{k=1 \\ k \neq i}}^n |a_{ik}| \quad \forall i = 1, \dots, n, \quad (5)$$

- **strikt diagonaldominant**, falls (5) mit “>” für *alle* $i \in \{1, \dots, n\}$ gilt,
- **diagonaldominant**, falls (5) mit “>” für *ein* $i \in \{1, \dots, n\}$ gilt.

Satz

Sei $A \in \mathbb{R}^{n \times n}$ regulär und diagonaldominant. Dann gibt es eine LR-Zerlegung

$$A = L \cdot R.$$

Symmetrisch positiv definite Matrizen

Definition

Eine Matrix $A \in \mathbb{R}^{n \times n}$ heißt

- (i) *positiv definit*, wenn $x^T A x > 0$ für alle $x \in \mathbb{R}^n$ mit $x \neq 0$ ist;
- (ii) *symmetrisch positiv definit (s.p.d.)*, wenn sie symmetrisch und positiv definit ist.

Satz (Eigenschaften positiver definiter Matrizen)

Sei $A \in \mathbb{R}^{n \times n}$ s.p.d., dann gilt:

- i) A ist invertierbar,
- ii) $a_{ii} > 0$ für alle $i = 1, \dots, n$,
- iii) $\max_{i,j=1,\dots,n} |a_{ij}| = \max_{i=1,\dots,n} a_{ii}$,
- iv) bei der Gauß-Elimination ohne Pivotsuche ist jede Restmatrix wiederum s.p.d..

- Erster Eliminationsschritt für s.p.d. $A^{(1)} = A$ (mit $z = (a_{12}, \dots, a_{1n})^T$):

$$A^{(2)} = L_1 A^{(1)} = \left(\begin{array}{c|ccc} 1 & & & \\ -l_{21} & 1 & & \\ \vdots & & \ddots & \\ -l_{n1} & & & 1 \end{array} \right) \left(\begin{array}{c|c} a_{11} & z^T \\ \hline z & B^{(1)} \end{array} \right) = \left(\begin{array}{c|c} a_{11} & z^T \\ \hline 0 & B^{(2)} \end{array} \right).$$

- Multiplikation von rechts mit L_1^T (regulär) liefert

$$L_1 A^{(1)} L_1^T = \left(\begin{array}{c|ccc} a_{11} & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & B^{(2)} & \\ 0 & & & \end{array} \right),$$

mit unveränderter Teilmatrix $B^{(2)}$.

~> Teilmatrix $B^{(2)}$ ist ebenfalls symmetrisch positiv definit.

- ▶ Multiplikation von rechts mit L_1^T liefert

$$L_1 A^{(1)} L_1^T = \left(\begin{array}{c|ccc} a_{11} & 0 & \cdots & 0 \\ \hline 0 & & & \\ \vdots & & B^{(2)} & \\ 0 & & & \end{array} \right).$$

- ▶ Fortsetzen dieser Konstruktion für $k = 2, \dots, n-1$ liefert,

$$L_{n-1} \cdots L_1 A L_1^T \cdots L_{n-1}^T = D.$$

- ▶ bzw. $A = LDL^T$,
 - ▶ mit L als Produkt der $L_1^{-1}, \dots, L_{n-1}^{-1}$,
 - ▶ und D als Diagonalmatrix der Pivotelemente.
- ▶ Beachte: die Konstruktion ist eindeutig.

Konstruktion der Cholesky-Zerlegung

Satz (Rationale Cholesky-Zerlegung)

Für jede s.p.d. Matrix A existiert eine eindeutig bestimmte Zerlegung der Form

$$A = LDL^T,$$

wobei L : unipotente untere Dreiecksmatrix und D : positive Diagonalmatrix.

Definition (Cholesky-Zerlegung)

Sei $A \in \mathbb{R}^{n \times n}$ s.p.d. mit rationaler Cholesky-Zerlegung $A = LDL^T$. Dann heißt

$$A = \bar{L} \bar{L}^T,$$

mit $\bar{L} := LD^{1/2}$, $D^{1/2} := \text{diag}(\pm\sqrt{d_i})$ **Cholesky-Zerlegung** von A .

Cholesky-Algorithmus

$$\begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & & & \vdots \\ \vdots & & & \vdots \\ a_{n1} & \cdots & \cdots & a_{nn} \end{pmatrix} \stackrel{!}{=} \begin{pmatrix} l_{11} & & & \\ l_{21} & l_{22} & & \\ \vdots & & \ddots & \\ l_{n1} & l_{n2} & \cdots & l_{nn} \end{pmatrix} \begin{pmatrix} l_{11} & l_{21} & \cdots & l_{n1} \\ & l_{22} & & l_{n2} \\ & & \ddots & \vdots \\ & & & l_{nn} \end{pmatrix}$$

$$= \begin{pmatrix} l_{11}^2 & l_{11}l_{21} & l_{11}l_{31} & \cdots & l_{11}l_{n1} \\ l_{11}l_{21} & l_{21}^2 + l_{22}^2 & l_{21}l_{31} + l_{22}l_{32} & \cdots & l_{21}l_{n1} + l_{22}l_{n2} \\ l_{11}l_{31} & l_{21}l_{31} + l_{22}l_{32} & l_{31}^2 + l_{32}^2 + l_{33}^2 & \cdots & l_{31}l_{n1} + l_{32}l_{n2} + l_{33}l_{n3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ l_{11}l_{n1} & l_{21}l_{n1} + l_{22}l_{n2} & l_{31}l_{n1} + l_{32}l_{n2} + l_{33}l_{n3} & \cdots & \sum_{j=1}^n l_{nj}^2 \end{pmatrix}$$

↪ Diagonalelemente: $a_{kk} = \sum_{j=1}^k l_{kj}^2$,

↪ Unterhalb der Diagonalen: $a_{ik} = \sum_{j=1}^k l_{kj} \cdot l_{ij}$, $k+1 \leq i \leq n$.

Cholesky-Verfahren zur Berechnung von L mit $A = LL^T$

Spaltenweise berechnet man für $k = 1, 2, \dots, n$

$$l_{kk} = \left(a_{kk} - \sum_{j=1}^{k-1} l_{kj}^2 \right)^{1/2}$$

$$l_{ik} = \frac{1}{l_{kk}} \left(a_{ik} - \sum_{j=1}^{k-1} l_{ij} \cdot l_{kj} \right), \quad k+1 \leq i \leq n.$$

Satz (Rechenaufwand Cholesky-Zerlegung)

Sei $A \in \mathbb{R}^{n \times n}$ symmetrisch positiv definit, dann gilt

$$\text{FLOP}(\text{Cholesky-Zerl. von } A) = \frac{2n^3 + 3n^2 - 5n}{6} + n \text{ Wurzeln} = \frac{1}{3}n^3 + \mathcal{O}(n).$$

Bemerkung

- Aus der Cholesky-Zerlegung $A = LL^T$ ergibt sich für $1 \leq k \leq n$ die Abschätzung

$$\sum_{j=1}^k l_{kj}^2 \leq \max_{1 \leq j \leq n} |a_{jj}|.$$

- ↪ Alle Elemente von L sind betragsweise durch $\max_{1 \leq j \leq n} \sqrt{|a_{jj}|}$ beschränkt.
- ↪ Die Elemente von L können nicht allzu stark anwachsen.
- ↪ Wirkt sich günstig auf die Stabilität des Verfahrens aus.

- Bei der algorithmischen Durchführung der Cholesky-Zerlegung liefert das Verfahren auch die Information, ob die Matrix positiv definit ist.

Bandmatrizen

Definition


Unter der **Bandbreite** m einer symmetrischen Matrix $A \in \mathbb{R}^{n \times n}$ versteht man die kleinste natürliche Zahl $m < n$, so dass gilt

$$a_{ik} = 0, \quad \text{für alle } i \text{ und } k \quad \text{mit} \quad |i - k| > m.$$

- ▶ Die Bandbreite gibt also die *Anzahl der Nebendiagonalen* mit nicht-verschwindenden Elementen an.
- ▶ Verallgemeinerter Form: *untere* und *obere Bandbreite*

Bandmatrizen

Beispiel Speicherschema für symmetrisch positiv definite Bandmatrizen:



Satz

Sei A eine s.p.d. Bandmatrix mit Bandbreite m und Cholesky-Zerlegung $A = LL^T$. Dann besitzt L dieselbe Bandstruktur, d.h.

$$l_{ik} = 0 \quad \text{für alle } i, k \text{ mit } i - k > m.$$

Algorithmus

- Analog zur Herleitung des Cholesky-Verfahrens.
- Schematisch für $n = 5$ und $m = 2$:

$$\begin{pmatrix} l_{11} & 0 & 0 & 0 & 0 \\ l_{21} & l_{22} & 0 & 0 & 0 \\ l_{31} & l_{32} & l_{33} & 0 & 0 \\ 0 & l_{42} & l_{43} & l_{44} & 0 \\ 0 & 0 & l_{53} & l_{54} & l_{55} \end{pmatrix} \begin{pmatrix} l_{11} & l_{21} & l_{31} & 0 & 0 \\ 0 & l_{22} & l_{32} & l_{42} & 0 \\ 0 & 0 & l_{33} & l_{43} & l_{53} \\ 0 & 0 & 0 & l_{44} & l_{54} \\ 0 & 0 & 0 & 0 & l_{55} \end{pmatrix} \\
 = \begin{pmatrix} l_{11}^2 & & & & \\ l_{11}l_{21} & l_{22}^2 + l_{21}^2 & & & \\ l_{11}l_{31} & l_{22}l_{32} + l_{21}l_{31} & l_{33}^2 + l_{32}^2 + l_{31}^2 & & \\ 0 & l_{22}l_{42} & l_{33}l_{43} + l_{32}l_{42} & l_{44}^2 + l_{43}^2 + l_{42}^2 & \\ 0 & 0 & l_{33}l_{53} & l_{44}l_{54} + l_{43}l_{53} & l_{55}^2 + l_{54}^2 + l_{53}^2 \end{pmatrix} \quad \text{sym.}$$

Algorithmus

Cholesky-Verfahren zur Berechnung von L mit $A = LL^T$, wobei $A \in \mathbb{R}^{n \times n}$ mit Bandbreite $0 \leq m < n$.

Für $k = 1, 2, \dots, n$:

$$l_{kk} = \left(a_{kk} - \sum_{j=\max\{1, k-m\}}^{k-1} l_{kj}^2 \right)^{1/2}$$

$$l_{ik} = \frac{1}{l_{kk}} \left(a_{ik} - \sum_{j=\max\{1, k-m\}}^{k-1} l_{ij} \cdot l_{kj} \right), \quad k+1 \leq i \leq \min\{k+m, n\}.$$

Aufwand

Satz

Es sei $A \in \mathbb{R}^{n \times n}$ eine s.p.d. Bandmatrix mit Bandbreite $1 \leq m \leq n$.

Dann beträgt der Aufwand zur Berechnung der Cholesky-Zerlegung von A

$$\begin{aligned} \text{FLOP}(\text{Cholesky-Zerl. von } A) &= n(m^2 + 2m) - \frac{4m^3 + 9m^2 + 5m}{6} \\ &\quad + n \text{ Wurzelberechnungen} \\ &= \mathcal{O}(n m^2). \end{aligned}$$

Beispiel (Auslenkung einer Saite)

- ▶ Gegeben sei eine elastische Saite der Länge 1, die an beiden Enden fixiert ist.
- ▶ Die Saite wird nun durch eine äußere Kraft f ausgelenkt.
- ▶ Wir wollen die Auslenkung u der Saite aus ihrer Ruhelage als Funktion von $x \in [0, 1]$ berechnen.
- ▶ Die gesuchte Auslenkung $u : [0, 1] \rightarrow \mathbb{R}$ ist Lösung des folgenden linearen Randwertproblems zweiter Ordnung:

$$-u''(x) + \lambda(x)u(x) = f(x), \quad x \in (0, 1), \quad u(0) = u(1) = 0, \quad (6)$$

mit gegebenen $f : (0, 1) \rightarrow \mathbb{R}$ und $\lambda : (0, 1) \rightarrow \mathbb{R}$ mit $\lambda(x) \geq 0$ für $x \in (0, 1)$.

Beispiel (Bestimmung einer Näherungslösung)

- ▶ Für $n_h \in \mathbb{N}$ unterteile $[0, 1]$ in $(n_h + 1)$ Teilintervalle der Länge $h = \frac{1}{n_h + 1}$.
- ▶ Knoten: $x_i := ih$, $i = 0, \dots, n_h + 1$ ($x_0 = 0, x_{n_h + 1} = 1$).
- ▶ Ziel: Lösung an den Knoten x_i approximieren ($u_i \approx u(x_i)$).
- ▶ Ersetze hierzu die zweite Ableitung durch den zentralen Differenzenquotienten (vgl. Analysis)

$$u''(x_i) \approx \frac{1}{h^2} (u(x_{i-1}) - 2u(x_i) + u(x_{i+1})) =: D_{c;h}^2 u(x_i).$$

Falls $u \in C^4[0, 1]$, gilt: $\|u'' - D_{c;h}^2 u\| = \mathcal{O}(h^2)$.

Beispiel (Bestimmung einer Näherungslösung)

- Ersetze hierzu die zweite Ableitung durch den zentralen Differenzenquotienten

$$u''(x_i) \approx \frac{1}{h^2} (u(x_{i-1}) - 2u(x_i) + u(x_{i+1})).$$

- Anwendung für das Randwertproblem (6) liefert:

$$\begin{cases} \frac{1}{h^2}(-u_{i-1} + 2u_i - u_{i+1}) + \lambda_i u_i = f_i, & \text{für } 1 \leq i \leq n_h, \\ u_0 = u_{n_h+1} = 0. \end{cases}$$

Beispiel (Bestimmung einer Näherungslösung)

- Anwendung für das Randwertproblem (6) liefert:

$$\begin{cases} \frac{1}{h^2}(-u_{i-1} + 2u_i - u_{i+1}) + \lambda_i u_i = f_i, & \text{für } 1 \leq i \leq n_h, \\ u_0 = u_{n_h+1} = 0, \end{cases}$$

- also ein lineares Gleichungssystem $A_h u_h = f_h$:

$$\underbrace{\begin{bmatrix} (2 + h^2 \lambda_1) & -1 & & 0 \\ -1 & (2 + h^2 \lambda_2) & \ddots & \\ & \ddots & \ddots & -1 \\ 0 & & -1 & (2 + h^2 \lambda_n) \end{bmatrix}}_{=: A_h} \underbrace{\begin{bmatrix} u_1 \\ \vdots \\ \vdots \\ u_{n_h} \end{bmatrix}}_{=: u_h} = \underbrace{\begin{bmatrix} h^2 f_1 \\ \vdots \\ \vdots \\ h^2 f_{n_h} \end{bmatrix}}_{=: f_h}.$$